Pratique: Matrice de Confusion

```
In [1]: # Lire les données dans un dataframe
    import pandas as pd
    url = 'https://archive.ics.uci.edu/ml/machine-learning-databases/pima-indians-diabetes/pima-indians-diabetes.data
    col_names = ['pregnant', 'glucose', 'bp', 'skin', 'insulin', 'bmi', 'pedigree', 'age', 'label']
    pima = pd.read_csv(url, header=None, names=col_names)
In [14]: # print les 5 premieres lignes
    pima.head()
```

Out[14]:

	pregnant	glucose	bp	skin	insulin	bmi	pedigree	age	label
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1

```
In [ ]: #shape
pima.shape
```

prediction du statut diabetique selon les prédicteurs

```
In [3]: # definir les predicteurs X
    feature_cols = ['pregnant', 'insulin', 'bmi', 'age']
    X = pima[feature_cols]
    #definir la cible y
    y = pima.label
```

```
In [8]: # split X et y ev training et testing
         from sklearn.model selection import train test split
         X train, X test, y train, y test = train test split(X, y, random state=42)
 In [9]: # train un modele logistic regression sur training
         from sklearn.linear model import LogisticRegression
         logreg = LogisticRegression()
         logreg.fit(X train, y train)
 Out[9]: LogisticRegression(C=1.0, class_weight=None, dual=False, fit_intercept=True,
                   intercept scaling=1, max iter=100, multi class='ovr', n jobs=1,
                   penalty='12', random state=None, solver='liblinear', tol=0.0001,
                   verbose=0, warm start=False)
In [10]: # Faire des predictions avec testing
         y pred class = logreg.predict(X test)
In [11]: # calcul du metrique accuracy
         from sklearn import metrics
         print("Accuracy:{} ".format(metrics.accuracy score(y test, y pred class)))
         Accuracy: 0.6927083333333334
In [12]: # Afficher la distribution de classe du testing set
         y test.value counts()
Out[12]: 0
              130
               62
         Name: label, dtype: int64
In [15]: # calcul des pourcentage de ones (1)
         y test.mean()
Out[15]: 0.6770833333333333
In [16]: # calcul des pourcentage de ones (0)
         1 - y test.mean()
Out[16]: 0.67708333333333333
```

```
In [17]: # Afficher les 20 premieres valeurs predites de statut
    print('True:', y_test.values[0:20])
    print('Pred:', y_pred_class[0:20])
    True: [1 0 0 1 0 0 1 1 0 0 0 1 0 0 0]
```

Matrice de confusion

```
In [18]: # Matrice de confusion: first argument is true values, second argument is predicted values
print(metrics.confusion_matrix(y_test, y_pred_class))
[[118 12]
```

- Definir d'abord l'hypothese nulle et l'hypothese alternative
- Terminologie pour lire la matrice de confusion
- True Positives (TP): On a prédit correctement qu'il a le diabete
- True Negatives (TN): On a prédit correctement qu'il n'a pas le diabete
- False Positives (FP): On a incorrectement predit qu'il a le diabete ("Type I error")
- False Negatives (FN): On a incorrectement predit qu'il n'a pas le diabetes ("Type II error")

```
In [21]: # Obtenir les 4 valeurs de la matrice
    confusion = metrics.confusion_matrix(y_test, y_pred_class)
    TP = confusion[1, 1]
    TN = confusion[0, 0]
    FP = confusion[0, 1]
    FN = confusion[1, 0]
```

```
In [22]: # Classification Accuracy:
# On doit repondre à la question: Globalement, quel est le pourcentage où le modele est correct?
print((TP + TN) / float(TP + TN + FP + FN))
print(metrics.accuracy_score(y_test, y_pred_class))
```

0.692708333333
0.6927083333333

[47 15]]

```
In [23]: #Classification Error:
         # On doit repondre à la question: Globalement, quel est le pourcentage où le modele est incorrect?
         print((FP + FN) / float(TP + TN + FP + FN))
         print(1 - metrics.accuracy score(y test, y pred class))
         0.307291666667
         0.307291666667
 In [ ]: |#Sensitivity:
         # On doit repondre à la question: Quand la valeur vraie est positive, combien de fois la prediction est correcte
         # Ou How "sensitive" is the classifier to detecting positive instances?
         #Aussi connu sous: "True Positive Rate" or "Recall"
In [24]: print(TP / float(TP + FN))
         print(metrics.recall score(y test, y pred class))
         0.241935483871
         0.241935483871
 In [ ]: |#Specificity:
         # On doit repondre à la question: Quand la valeur vraie est negative, combien de fois la prediction est correcte
         #OU How "specific" (or "selective") is the classifier in predicting positive instances?
In [25]: print(TN / float(TN + FP))
         0.907692307692
In [26]: #False Positive Rate:
         # On doit repondre à la question: Quand la valeur vraie est negative, combien de fois la prediction est incorrect
         print(FP / float(TN + FP))
         0.0923076923077
 In [ ]: # Precision:
         # On doit repondre à la question: Quand une valeur positive est predite, combien de fois la prediction est correc
```

#OU How "precise" is the classifier when predicting positive instances?

```
In [27]: print(TP / float(TP + FP))
    print(metrics.precision_score(y_test, y_pred_class))

0.55555555556

In []: de
    Which metrics should you focus on?
    Choice of metric depends on your business objective
    Spam filter (positive class is "spam"): Optimize for precision or specificity because false negatives (spam goes Fraudulent transaction detector (positive class is "fraud"): Optimize for sensitivity because false positives (notes)
```